

ÉCOLE D'INGÉNIEURS
PROJET BUSINESS INTELLIGENCE

**Mise en Place d'un Data
Warehouse
avec Talend Open Studio**

*Processus ETL pour la Gestion
d'une École d'Ingénieurs*

Réalisé par :

SYLLA N'faly
EL ADNANI EL Mehdi
CHAIBERRAS Souhail

Encadré par :

Pr. Hassan BADIR

Année Universitaire 2025-2026

Table des matières

1	Introduction	2
1.1	Contexte du Projet	2
1.2	Objectifs Opérationnels	2
1.3	Périmètre Fonctionnel et Volumétrie	2
2	Modélisation Dimensionnelle	3
2.1	Choix Architectural : Le Schéma en Étoile	3
2.2	Dictionnaire des Données	3
2.2.1	Les Dimensions (Contexte d'Analyse)	3
2.2.2	Les Faits (Mesures et Indicateurs)	4
3	Génération des Données Source	5
3.1	Stratégie de Simulation et Méthodologie	5
3.2	Corpus de Données Généré	5
3.3	Qualité et Diversité de l'Échantillon	6
4	Implémentation ETL avec Talend	7
4.1	Chargement des Dimensions	7
4.1.1	Dimensions Simples	7
4.1.2	Dimensions avec Jointures et Filtrage	9
4.2	Chargement des Tables de Faits	10
4.2.1	Job FAIT_Absences	10
4.2.2	Job FAIT_Notes	11
4.2.3	Job FAIT_Stage	12
4.2.4	Job FAIT_Heure_Enseignement	13
4.3	Transformations Transverses	13
5	Résultats et Statistiques	14
5.1	Bilan des Chargements	14
5.2	Analyse de la Donnée	14
5.2.1	Répartition par Niveau	14
5.2.2	Répartition des Stages	14
6	Synthèse de la mise en place sous Power BI	15
6.1	Conclusion Générale	16
	Annexe A : Capture du tableau de bord Power BI	17
	Annexe B : Modèle de données Power BI	18
	Annexe C : Extraits du script de préparation des données	18

1 | Introduction

1.1 Contexte du Projet

Dans une démarche de modernisation du système d'information, notre école d'ingénieurs a initié la conception d'un entrepôt de données. Ce projet vise à centraliser et analyser les flux d'informations relatifs à la gestion pédagogique et administrative.

Le système décisionnel a pour vocation de fournir aux acteurs clés (direction, coordinateurs, enseignants) des indicateurs de pilotage précis via Power BI, couvrant quatre axes stratégiques :

1. Le suivi de l'assiduité et des absences.
2. L'analyse des performances académiques (notes et résultats).
3. La gestion des relations entreprises et des stages.
4. Le pilotage de la charge et du volume horaire des enseignants.

1.2 Objectifs Opérationnels

Les objectifs techniques et fonctionnels de cette phase du projet sont multiples :

- **Modélisation** : Concevoir un schéma en étoile optimisé pour l'analytique.
- **Simulation** : Générer un jeu de données réaliste et cohérent pour peupler l'entrepôt.
- **Intégration** : Implémenter les flux ETL (Extract, Transform, Load) sous Talend Open Studio.
- **Qualité** : Garantir l'intégrité référentielle entre les dimensions et les faits.
- **Restitution** : Préparer le socle de données pour l'exploitation sous Power BI.

1.3 Périmètre Fonctionnel et Volumétrie

Le périmètre de l'étude couvre l'intégralité des cursus de l'école :

Cycle Préparatoire (600 étudiants)

Répartis sur les niveaux AP1 et AP2.

Cycle Ingénieur (1080 étudiants)

Répartis sur 3 années (CI1, CI2, CI3) et organisés en 6 filières de spécialisation (Informatique, Industrielle, Électronique, Télécommunications, Cybersécurité et Énergie).

2 | Modélisation Dimensionnelle

2.1 Choix Architectural : Le Schéma en Étoile

Pour répondre aux exigences de performance des requêtes décisionnelles, nous avons retenu une architecture en ****schéma en étoile**** (Star Schema). Contrairement au modèle relationnel normalisé (3NF) utilisé dans les bases de production, ce modèle dénormalisé place les mesures au centre et les axes d'analyse en périphérie.

Ce choix stratégique offre trois avantages majeurs :

- **Lisibilité accrue** : La structure est intuitive pour les utilisateurs métiers (Power BI).
- **Performance** : La réduction du nombre de jointures optimise les temps de réponse.
- **Évolutivité** : L'ajout de nouvelles dimensions n'impacte pas la structure existante.

2.2 Dictionnaire des Données

L'architecture du Data Warehouse repose sur la convergence de 7 axes d'analyse et de 4 processus métiers distincts.

2.2.1 Les Dimensions (Contexte d'Analyse)

Les tables de dimension contiennent les attributs descriptifs (le "qui", "quoi", "où", "quand") permettant de filtrer et regrouper les données.

TABLE 2.1 – Dictionnaire des Dimensions

Table	Description Fonctionnelle	Clé Primaire
DIM_Filieres	Spécialisations académiques (Génie Logiciel, etc.)	<i>FiliereID</i>
DIM_Semestres	Axe temporel académique (Semestres S1-S6)	<i>SemestreID</i>
DIM_Groupes	Granularité fine des classes (TD/TP)	<i>GroupID</i>
DIM_Matieres	Catalogue des modules d'enseignement	<i>MatiereID</i>
DIM_Etudiants	Données des élèves	<i>StudentID</i>
DIM_Enseignants	Référentiel du corps professoral	<i>EnseignantID</i>
DIM_Entreprises	Référentiel des partenaires professionnels	<i>EntrepriseID</i>

2.2.2 Les Faits (Mesures et Indicateurs)

Les tables de faits centralisent les métriques quantitatives et les clés étrangères assurant la liaison avec les dimensions.

TABLE 2.2 – Dictionnaire des Tables de Faits

Table	Processus Métier	Mesures Clés
FAIT_Absences	Pilotage de l'assiduité et du présentéisme	<i>DurationHours</i>
FAIT_Notes	Analyse de la performance académique	<i>Note, Coefficient</i>
FAIT_Stages	Suivi de l'insertion professionnelle	<i>Grade</i>
FAIT_Heures	Calcul de la charge horaire enseignante	<i>VolumeHoraire</i>

3 | Génération des Données Source

3.1 Stratégie de Simulation et Méthodologie

Face aux contraintes de confidentialité (RGPD) limitant l'accès aux données de production réelles, nous avons opté pour le développement d'un moteur de **génération de données synthétiques** en Python.

Cette approche programmatique répond à trois exigences techniques majeures :

- **Intégrité Structurale** : Le script garantit nativement la cohérence des clés étrangères (ex : un étudiant généré est obligatoirement rattaché à un groupe existant).
- **Réalisme Contextuel** : Utilisation de bibliothèques spécifiques pour générer des identités crédibles (noms et prénoms à consonance marocaine) afin de faciliter la lecture des tableaux de bord.
- **Reproductibilité** : L'implémentation d'une "graine aléatoire" (*seed*) permet de régénérer le même jeu de données à l'identique pour valider les tests de régression.

3.2 Corpus de Données Généré

L'exécution du script produit un ensemble de **11 fichiers plats (CSV)**. L'ordre de génération et de numérotation des fichiers n'est pas anodin : il respecte la hiérarchie des dépendances pour éviter les erreurs d'intégrité lors de l'injection ETL.

TABLE 3.1 – Inventaire des fichiers sources (Ordre séquentiel d'injection)

Ordre	Nom du Fichier	Volumétrie	Type de Donnée
1	1_filieres.csv	6	Référentiel
2	2_groupes.csv	56	Référentiel
3	3_students.csv	1 680	Dimension
4	4_enseignants.csv	79	Dimension
5	5_entreprises.csv	20	Référentiel
6	6_semestres.csv	4	Référentiel
7	7_matieres.csv	35	Référentiel
8	8_absences.csv	8 180	Transactionnel (Fait)
9	9_notes.csv	13 367	Transactionnel (Fait)
10	10_stages.csv	1 476	Transactionnel (Fait)
11	11_heures_enseignement.csv	1 063	Transactionnel (Fait)

3.3 Qualité et Diversité de l'Échantillon

Afin d'assurer la pertinence des tests, une attention particulière a été portée à la diversité des données générées. Le dictionnaire de données inclut plus de ****200 noms de famille**** et ****200 prénoms**** distincts, permettant de générer plus de 40 000 combinaisons uniques.

4 | Implémentation ETL avec Talend

L'alimentation du Data Warehouse repose sur Talend Open Studio. Nous avons structuré nos développements en deux catégories de jobs.

4.1 Chargement des Dimensions

4.1.1 Dimensions Simples

Les jobs de dimension suivent un schéma "Extract-Transform-Load" classique.




FIGURE 4.1 – Job dim_filiere - Flux simple

Le job `dim_filiere` lit le fichier source, applique un horodatage via `tMap` et insère les données.




FIGURE 4.2 – Job dim_enseignant - Flux simple

Le job `dim_enseignant` suit le même pattern : lecture du fichier source `Enseignant`, application d'une transformation via `tMap_1`, puis insertion dans la base de données via `tDBOutput_1` et export en fichier délimité via `tFileOutputDelimited_1`. Ce flux

traite 79 lignes en 0.02s, mettant en évidence l'efficacité des dimensions simples sans dépendances externes.

Dimensions avec Règles de Gestion Certaines dimensions nécessitent des transformations conditionnelles.





FIGURE 4.3 – Job dim_matiere - Gestion des clés étrangères


Pour la dimension Matières, nous gérons les valeurs nulles (cas des matières de prépa sans filière) via l'expression Java suivante dans le tMap :

```
row1.FiliereID.isEmpty() ? null : Integer.parseInt(row1.FiliereID)
```

De même, les jobs DimSemestre et dim_entreprise assurent le chargement des référentiels temporels et partenaires.



(a) Job DimSemestre



(b) Job dim_entreprise

FIGURE 4.4 – Autres jobs de dimension

4.1.2 Dimensions avec Jointures et Filtrage

Certains jobs nécessitent des architectures plus élaborées combinant sources multiples, jointures et filtrage pour gérer les dépendances métier.

Job avec Filtrage Optimisé




FIGURE 4.5 – Job dim_groupe - Filtrage en amont

Ce job démontre l'optimisation par filtrage précoce : la source *filiere1* est filtrée (56 lignes réduites à 6) avant la jointure, tandis que *group1* fournit également un sous-ensemble de données. La jointure dans *tMap_1* combine ces données filtrées, traitant 336 lignes en 0.27s. Cette stratégie applique les contraintes métier le plus tôt possible dans le pipeline ETL pour améliorer les performances globales.

Job avec Jointures Complexes




FIGURE 4.6 – Job avec jointures multi-sources - Architecture complexe

Ce job illustre une architecture plus élaborée combinant trois sources (*student1*, *filiere1*, *group1*) via une jointure complexe dans *tMap_1*. Le flux traite 1 680 lignes en 44.99s avant la jointure, puis génère 564 480 lignes en sortie en 45.18s. Les branches pointillées représentent les chemins conditionnels pour la gestion des cas particuliers.

(valeurs nulles, clés étrangères manquantes). Les deux sorties (tDBOutput_1 et tFileOutputDelimited) garantissent la persistance en base de données et l'archivage en fichier.

4.2 Chargement des Tables de Faits

Les tables de faits nécessitent de récupérer les clés techniques des dimensions via des jointures (Lookups).

4.2.1 Job FAIT_Absences

Ce job illustre l'architecture complexe avec multiples lookups.




FIGURE 4.7 – Job fact_absences - Orchestration complète

Le flux principal (CSV Absences) est enrichi par 4 lookups :

1. **dim_etudiant** (sur StudentID)
2. **dim_matiere** (sur MatiereID)
3. **dim_groupe** (sur GroupID)
4. **dim_semestre** (sur SemestreID)

Configuration des Lookups : Nous utilisons le mode *"Load Once"* (chargement en cache) et *"Inner Join"* pour garantir que seules les absences liées à des étudiants existants sont intégrées.

4.2.2 Job FAIT_Notes

Suivant la même logique, ce job a permis l'intégration massive des résultats académiques.




FIGURE 4.8 – Job fact_notes

4.2.3 Job FAIT_Stage

Ce job démontre une architecture encore plus complexe avec cinq sources principales et lookups multiples pour enrichir les données de stage.




FIGURE 4.9 – Job fact_stage - Orchestration avec cinq sources

Le flux combine quatre sources principales (stage, student1, entreprise, filiere1) et une source supplémentaire (semestre) via une jointure centrale dans tMap_1. Le flux traite :

- Source stage : 4 lignes en 567.13s
- Source student1 : 1 680 lignes en 0.04s
- Source entreprise : 20 lignes en 0.01s
- Source filiere1 : 4 lignes réduites à 4 après filtrage
- Source semestre : 4 lignes en 0s

La sortie finale génère 2 665 158 lignes en 624.98s, stockées via tDBOutput_1 et exportées en fichier délimité par tFileOutputDelimited_1. L'utilisation de lookups en mode "Load Once" avec "Inner Join" garantit l'intégrité référentielle en n'intégrant que les stages associés à des entités existantes dans les dimensions.

4.2.4 Job FAIT_Heure_Enseignement

Ce job démontre une architecture complexe avec quatre dimensions liées via des lookups pour enrichir les données d'heures d'enseignement.




FIGURE 4.10 – Job fact_heure - Orchestration avec lookups multiples

Le flux principal est alimenté par la source heure et enrichi par quatre lookups :

1. **matiere** (row1 lookup)
2. **Enseignant** (row2 lookup)
3. **group1** (row4 lookup)
4. **semestre** (row5 lookup)

La jointure centrale dans tMap_1 combine toutes ces sources, générant une sortie stockée via tDBOutput_1 et exportée en fichier délimité par tFileOutputDelimited_1. Cette architecture garantit l'intégrité référentielle en utilisant le mode "Load Once" et "Inner Join" pour les lookups.

4.3 Transformations Transverses

Des fonctions standards ont été appliquées sur l'ensemble des flux :

- **Dates** : Conversion via `TalendDate.parseDate("yyyy-MM-dd", ...)`.
- **Traçabilité** : Ajout d'une colonne `DateCreation` via `TalendDate.getCurrentDate()`.

5 | Résultats et Statistiques

5.1 Bilan des Chargements

L'exécution des jobs a été un succès total, avec 100% des données intégrées.

5.2 Analyse de la Donnée

Les données chargées présentent une structure cohérente et réaliste.

5.2.1 Répartition par Niveau

L'algorithme de génération a assuré une distribution équilibrée des effectifs :

TABLE 5.1 – Répartition des Étudiants

Niveau	Effectif	Part (%)
AP1 (Prépa 1ère année)	300	17.86%
AP2 (Prépa 2ème année)	300	17.86%
CI1 (Ingénieur 1ère année)	360	21.43%
CI2 (Ingénieur 2ème année)	360	21.43%
CI3 (Ingénieur 3ème année)	360	21.43%
Total	1680	100%

5.2.2 Répartition des Stages

Les stages couvrent l'ensemble des types pédagogiques :

TABLE 5.2 – Typologie des Stages

Type	Nombre	Part (%)
OBSERVATION (Prépa)	514	34.82%
PP (Projet Personnel - CI1)	318	21.54%
PFA (Projet Fin d'Année - CI2)	325	22.02%
PFE (Projet Fin d'Études - CI3)	319	21.61%
Total	1476	100%

6 | Synthèse de la mise en place sous Power BI

À partir des données déjà nettoyées et structurées par l'équipe (11 fichiers CSV pour les dimensions et les faits), notre travail a consisté à construire dans Power BI un modèle décisionnel exploitable et des tableaux de bord interactifs pour la direction de l'école.

Modélisation dans Power BI

Les différentes tables ont été importées dans Power BI Desktop (encodage UTF-8, séparateur virgule) puis reliées selon un schéma en étoile :

- 7 tables de dimensions : étudiants, filières, groupes, matières, semestres, enseignants, entreprises.
- 4 tables de faits : absences, notes, stages, heures d'enseignement.

Toutes les relations sont de type *plusieurs-à-un* (N :1), avec une direction de filtre unique, afin de garantir un modèle simple, performant et facile à maintenir.

Mesures DAX principales

Sur ce modèle, nous avons créé un ensemble de mesures DAX pour calculer les indicateurs clés, notamment :

- **Absences** : total d'absences, heures manquées, taux d'absence, taux de justification, top étudiants les plus absents.
- **Notes** : moyenne générale, moyenne pondérée, taux de réussite, distribution des notes par tranches, mentions.
- **Stages** : nombre total de stages, répartition PFE/PFA/PP, durée moyenne des stages, stages par entreprise.
- **Enseignement** : volume horaire total, répartition CM/TD/TP, comparaison permanents/vacataires, charge moyenne par enseignant.

Ces mesures servent de base à tous les graphiques et cartes de KPI dans les dashboards.

Tableaux de bord réalisés

Cinq pages principales ont été développées dans Power BI :

- **Accueil** : vue globale sur les effectifs (étudiants, enseignants, entreprises) et quelques KPI synthétiques.
- **Absences** : suivi de l'assiduité par filière, niveau, sexe et période, avec un top 15 des étudiants les plus absents.
- **Notes** : analyse des performances académiques (moyennes, taux de réussite, distribution des notes, meilleurs étudiants).

- **Stages** : cartographie des entreprises partenaires, répartition des types de stages et top entreprises d'accueil.
- **Enseignants** : analyse du volume horaire par statut, qualification et filière, avec détection des surcharges.

Chaque page intègre des filtres (filière, semestre, type d'évaluation, etc.) et des interactions croisées, permettant aux décideurs de passer rapidement d'une vue globale à une analyse détaillée.

Apport de la solution Power BI

La mise en place de ce modèle et de ces tableaux de bord sous Power BI permet désormais :

- de centraliser les données pédagogiques et administratives de l'école dans un seul outil,
- de suivre en temps quasi réel les absences, les résultats, les stages et la charge enseignante,
- d'identifier plus facilement les situations à risque (absentéisme élevé, échecs répétés, surcharge d'enseignants),
- de fournir aux responsables une base fiable pour la prise de décision et l'amélioration continue des formations.

6.1 Conclusion Générale

Ce projet de tableaux de bord Power BI pour la gestion d'une école d'ingénieurs nous a permis de transformer un ensemble de fichiers CSV bruts en un système décisionnel complet, lisible et exploitable par les responsables pédagogiques et administratifs.

À partir des données nettoyées et structurées par l'équipe (étudiants, filières, notes, absences, stages, volume horaire), nous avons conçu un modèle en étoile dans Power BI, défini des mesures DAX pertinentes, puis construit cinq tableaux de bord interactifs couvrant les principaux axes de pilotage : assiduité, performances académiques, stages et partenariats, charge enseignante, ainsi qu'une vue d'ensemble.

La solution obtenue offre plusieurs apports concrets :

- centralisation des données clés de l'école dans un seul outil,
- visualisation instantanée des indicateurs (KPI) critiques,
- détection facilitée des situations à risque (absentéisme, échecs, surcharge d'enseignants),
- support objectif à la prise de décision et à l'amélioration continue des formations.

À terme, ce travail pourra être enrichi par l'ajout de nouvelles sources (enquêtes, insertion professionnelle), la mise en place d'alertes automatiques ou encore l'intégration de modèles prédictifs (prévision du risque d'échec, recommandations d'actions de remédiation), afin de faire évoluer cette solution vers une plateforme décisionnelle encore plus intelligente et proactive.

Annexe A : Capture du tableau de bord Power BI




FIGURE 1 – Exemple de tableau de bord Power BI pour la gestion de l'école d'ingénieurs

Annexe B : Modèle de données Power BI



FIGURE 2 – Modèle de données en étoile utilisé dans Power BI

Annexe C : Extraits du script de préparation des données

```

PS D:\Projects\bi-projects\datasets\ps1\scripts> python .\01_nettoyage_csv.py
Nettoyage: dim_etudiant...
1000 lignes exportées
Nettoyage: dim_filiere...
6 lignes exportées
Nettoyage: dim_groupe...
136 lignes exportées
Nettoyage: dim_matiere...
41 lignes exportées
Nettoyage: dim_semestre...
79 lignes exportées
Nettoyage: dim_enseignant...
20 lignes exportées
Nettoyage: fait_absences...
8179 lignes exportées
Nettoyage: fait_notes...
11382 lignes exportées
Nettoyage: fait_stages...
1476 lignes exportées
Nettoyage: fait_heures_enseignement...
1063 lignes exportées
RETENUE TERMINÉE - tous les fichiers dans 'data_clean/'

PS D:\Projects\bi-projects\datasets\ps1\scripts>

PS D:\Projects\bi-projects\datasets\ps1\scripts> python .\02_validation donnees.py
VALIDATION DES DIMENSIONS
dim_etudiant.csv - OK (1000 lignes)
dim_filiere.csv - Colonne manquante: ('filiere_cod', 'filiere_nom')
dim_groupe.csv - Colonne manquante: ('groupe_nom', 'annee_academique')
dim_matiere.csv - OK (41 lignes)
dim_semestre.csv - Colonne manquante: ('semestre_nom')
dim_enseignant.csv - OK (79 lignes)
dim_entreprise.csv - OK (20 lignes)
VALIDATION DES TABLES DE FAITS
fait_absences.csv - OK (8179 lignes)
fait_notes.csv - OK (11382 lignes)
fait_stages.csv - OK (1476 lignes)
fait_heures_enseignement.csv - OK (1063 lignes)
VALIDATION TERMINEE

PS D:\Projects\bi-projects\datasets\ps1\scripts>

PS D:\Projects\bi-projects\datasets\ps1\scripts> python .\02_validation donnees.py
VALIDATION DES DIMENSIONS
dim_etudiant.csv - OK (1000 lignes)
dim_filiere.csv - OK (6 lignes)
dim_groupe.csv - OK (136 lignes)
dim_matiere.csv - OK (41 lignes)
dim_semestre.csv - OK (4 lignes)
dim_enseignant.csv - OK (79 lignes)
dim_entreprise.csv - OK (20 lignes)
VALIDATION DES TABLES DE FAITS
fait_absences.csv - OK (8179 lignes)
fait_notes.csv - OK (11382 lignes)
fait_stages.csv - OK (1476 lignes)
fait_heures_enseignement.csv - OK (1063 lignes)
VALIDATION TERMINEE
  
```

(a) Chargement des fichiers CSV et configuration générale (b) Nettoyage des colonnes et normalisation des dates (c) Validation des clés et export des données nettoyées

FIGURE 3 – Extraits du script Python utilisé pour la préparation et la validation des données avant import dans Power BI